

# Detección y clasificación de fallos en motores a partir del análisis de señales acústicas.

David Pal (1749838), Nicolás Rivard (1750356), Pau Fernández (1748231), Iván Arias (1746259)

**Abstract—** Este proyecto presenta un sistema de detección y clasificación de fallos en motores industriales a partir del análisis de sus señales acústicas. Utilizando el dataset MIMII (ventiladores), se procesan las grabaciones mediante filtrado, extracción de coeficientes MFCC y Análisis Discriminante Lineal (LDA) para distinguir entre motores en estado nominal y motores con anomalías. Los resultados demuestran que la combinación de MFCCs y LDA permite una separación efectiva entre las cinco clases definidas (motor sano y cuatro tipos de fallo).

**Keywords—** Acoustic signal processing, Fourier transform, STFT, MFCC, PCA, fault detection, engine diagnosis.

## 1 INTRODUCCIÓN

En el contexto actual de la automoción, el mantenimiento preventivo es clave para evitar que fallos técnicos deriven en averías críticas con altos costes de reparación. Desde la perspectiva del procesamiento de señal, un motor actúa como un emisor de **firmas acústicas** que caracterizan su estado operativo. Este proyecto desarrolla un sistema de detección de anomalías basado en el análisis de estas señales, identificando alteraciones frecuenciales provocadas por fallos mecánicos como la falta de lubricación o el desequilibrio de componentes.

La solución consiste en capturar el audio del motor y transformarlo al dominio de la frecuencia mediante la **Transformada de Fourier de Tiempo Reducido (STFT)** para identificar patrones espectrales específicos. Tras el análisis visual de los espectrogramas, el sistema utiliza **Análisis Discriminante Lineal (LDA)** para la clasificación automática. A diferencia de los métodos no supervisados, el LDA permite maximizar la separabilidad entre las clases **"nominal"** y **"anómalo"** utilizando datos etiquetados (provenientes de datasets estándar como MIMII). Esto permite confirmar estadísticamente si las irregularidades observadas constituyen una falla mecánica, garantizando una clasificación robusta y una detección precoz de averías.

## 2 OBJETIVOS

Conseguir un sistema fiable que permita detectar fallos mecánicos en motores, además de clasificarlos.

- Usar técnicas de limpieza de datos para prepararlos
- Generar los espectrogramas usando STFT
- Identificar características en los espectrogramas para poder categorizar sus armónicos en motor sano o averiado
- Evaluar la fiabilidad del sistema usando LDA, usando datos etiquetados para contrastar la precisión del modelo con la realidad

## 3 STATE OF THE ART

El diagnóstico de fallos mecánicos en el ámbito del motor ha evolucionado significativamente con la digitalización del procesamiento de señales. Podemos dividir la actualidad en 3 pilares que cubren las áreas principales de nuestro proyecto.

### 3.1 Análisis de Vibraciones vs. Análisis Acústico

Tradicionalmente la técnica para detectar fallos mecánicos en diagnósticos preventivos se basa en el estudio de las vibraciones. Estos se basan en sensores colocados en contacto con las diferentes partes del motor. Como innovación, estudios demuestran que el análisis acústico no invasivo (mediante micrófonos) ofrece una alternativa eficaz y de bajo coste. Esta nueva técnica permite capturar la firma sonora del motor, que permite hacer diagnósticos rápidos.

### 3.2 Técnicas de Tiempo-Frecuencia (STFT)

Dado que las características y frecuencias de la señal acústica de un motor cambian en el tiempo, la Transformada de Fourier convencional resulta insuficiente. En este caso usaremos Transformada de Fourier de Tiempo Reducido (STFT) como el generador del espectrograma que nos ayudará a identificar patrones extraños en momentos específicos.

### 3.3 Extracción de Características y Reducción de Datos (MFCC y LDA)

En el reconocimiento de patrones sonoros, los coeficientes MFCC son superiores a la señal bruta al comprimir la información espectral según la percepción auditiva humana, eliminando frecuencias irrelevantes. Complementariamente, el Análisis Discriminante Lineal (LDA) es una técnica óptima para la detección de anomalías. A diferencia de otros métodos, el LDA es un enfoque supervisado que maximiza la separabilidad entre clases (motor sano - averiado), facilitando la creación de clústers robustos que identifican automáticamente cualquier desviación en las características de cada motor.

## 4 PROPOSTA

En este proyecto se propone el desarrollo de un sistema avanzado de diagnóstico basado en la caracterización de la firma acústica de motores industriales. La premisa fundamental es que las diversas patologías mecánicas —como obstrucciones o desequilibrios— alteran los patrones espectrales de funcionamiento nominal de forma específica. Mediante el uso de la **Transformada de Fourier de Tiempo Reducido (STFT)** y el **Análisis Discriminante Lineal (LDA)** sobre el dataset MIMII, el sistema no solo detectará la presencia de anomalías, sino que será capaz de clasificar el tipo de fallo mediante el procesamiento digital de señales y técnicas de aprendizaje supervisado.

### 4.1 Fase 1: Adquisición y Limpieza de Datos

En primer lugar, se grabarán o utilizarán audios de motores en dos estados: normal y con fallo. Las señales serán estandarizadas (media 0, desviación típica 1) para garantizar una amplitud uniforme. A continuación, se aplicará un filtro pasa-banda para eliminar frecuencias fuera del rango de interés del motor,

descartando tanto el ruido de baja frecuencia del entorno como las interferencias de alta frecuencia.

## 4.2 Fase 2: Análisis en el Dominio de la Frecuencia

El audio filtrado se transformará al dominio tiempo-frecuencia mediante STFT, dividiendo la señal en bloques de 20–50 ms con un solapamiento del 50%. El espectrograma resultante permitirá la inspección visual: un motor sano presenta líneas horizontales claras (armónicos estables), mientras que un motor con fallo muestra ruido de banda ancha o nuevas líneas de frecuencia debidas a fricción o desequilibrio. Debemos estudiar las diferentes características para determinar si estamos observando un motor en correcto funcionamiento o uno que presenta alguna anomalía.

## 4.3 Fase 3: Extracción de Características (MFCCs)

Dado que el espectrograma completo es demasiado voluminoso para un análisis directo, se extraerán los coeficientes MFCC de cada bloque temporal. Estos descriptores compactan la información espectral centrándose en la estructura sonora característica del motor y eliminando variaciones irrelevantes.

## 4.4 Fase 4: Clasificación y Separabilidad (LDA)

En esta fase, los vectores de características MFCC extraídos de las diversas máquinas (el dataset consta de 4 máquinas diferentes) se integran en un modelo de Análisis Discriminante Lineal (LDA). Al tratarse de un enfoque supervisado, el LDA busca los ejes que maximizan la separación entre estas cuatro categorías específicas. La proyección resultante no solo permite detectar la presencia de una anomalía, sino identificar cuál de las máquinas estamos observando mediante la formación de clústeres diferenciados para cada clase. La fiabilidad del sistema se validará analizando la precisión del clasificador en la distinción de fallos.

## 5 Data

El conjunto de datos MIMII es una colección de audio diseñada para el análisis y detección de fallos en maquinaria industrial. Incluye grabaciones de cuatro tipos de equipos: válvulas, bombas, ventiladores y rieles deslizantes.

Cada categoría agrupa distintos modelos específicos de máquinas, y para cada uno se dispone tanto de sonidos en condiciones normales como de sonidos asociados a anomalías. Con el fin de aproximarse a situaciones reales, se registraron diferentes tipos de fallos. Además, las grabaciones incorporan ruido de fondo procedente de varias fábricas, mezclado con el sonido propio de las máquinas, lo que hará que tengamos que limpiar los datos obligatoriamente. Nosotros trabajaremos con el dataset de ventiladores, y el objetivo será clasificar entre motores en correcto funcionamiento y motores con anomalías. También intentaremos separar los 4 motores diferentes usando LDA.

## 5 DESARROLLO Y METODOLOGÍA

El desarrollo de este sistema de diagnóstico de fallos industriales se ha estructurado como una evolución de los conceptos

trabajados en los laboratorios de la asignatura, combinando el filtrado temporal, la extracción de características frecuenciales y su posterior clasificación.

## 5.1 Fundamentos y referencias

Para construir el programa final, nos hemos basado en dos pilares fundamentales de las sesiones prácticas:

- **Lab 2 (Procesamiento de Audio):** De aquí hemos extraído la lógica del filtrado digital. Utilizamos un filtro Butterworth de paso alto para limpiar la señal de ruidos de baja frecuencia (zumbido eléctrico y vibraciones ambientales). También aplicamos el concepto de Espectrograma para la inspección visual inicial de las averías.
- **Lab 5 (Clasificación y LDA):** Utilizamos el **Análisis Discriminante Lineal (LDA)** como motor de clasificación, basándonos en su capacidad para maximizar la separabilidad entre clases etiquetadas, superando las limitaciones de otros métodos de reducción de dimensionalidad como el PCA en tareas de supervisión.

## 5.2 Fundamentos y referencias

El programa sigue un pipeline de datos secuencial:

1. **Carga Multiclase:** Se diseñó un cargador que recorre los diferentes IDs de las máquinas (id\_00, id\_02, id\_06) para capturar la variabilidad entre diferentes unidades del mismo modelo de ventilador.
2. **Preprocesado:** Cada audio se normaliza y se filtra para eliminar componentes no deseados.
3. **Extracción de Características (Feature Extraction):** Transformamos la señal de audio en vectores numéricos mediante coeficientes MFCC, que capturan la "huella dactilar" sonora del motor.
4. **Entrenamiento y Evaluación:** El modelo se entrena con un 70% de los datos y se evalúa con el 30% restante mediante una matriz de confusión.



## 5.3 Optimización de parámetros y resultados

Durante el desarrollo, realizamos experimentos variando dos parámetros críticos para ajustar la sensibilidad del sistema:

A. Coeficientes MFCC (De 13 a 40)

Caso MFCC=13: Proporcionó una clasificación básica, pero con un solapamiento significativo en el gráfico LDA. La información era insuficiente para distinguir fallos sutiles entre máquinas similares.



Caso MFCC=40: Al aumentar a 40 coeficientes, el sistema ganó resolución espectral. Aunque el gráfico 2D sigue mostrando proximidad entre algunas clases, la Matriz de Confusión demostró que, en el espacio multidimensional, el algoritmo separa los fallos con una precisión muy superior.



## B. Frecuencia de Corte (Cutoff) del Filtro (De 100Hz a 500Hz)

Cutoff = 100Hz: Se estableció como el valor óptimo. Logra eliminar el ruido de baja frecuencia sin perder la información fundamental de la rotación del ventilador y los primeros armónicos del fallo.

Cutoff = 500Hz: Tras probar este valor, los resultados empeoraron notablemente. Al filtrar por encima de 500Hz, eliminamos componentes esenciales de la firma acústica de la avería en las máquinas id\_00 e id\_02. Esto nos confirmó que la información diagnóstica clave se encuentra en el rango de frecuencias bajas-medias del espectro.



## 5.4 Conclusión del desarrollo

El programa final utiliza **MFCC=40** y **Cutoff=100Hz**. La interpretación de los resultados finales indica que, aunque el gráfico LDA proyectado a 2D muestra grupos solapados (especialmente entre las máquinas 00 y 02), la alta concentración de valores en la **diagonal principal de la Matriz de Confusión** valida que el sistema es capaz de diagnosticar correctamente la salud de los motores en un entorno industrial real.

## BIBLIOGRAFIA

Dataset --> <https://zenodo.org/records/3384388>

Colab -->

[https://colab.research.google.com/drive/1\\_y\\_3darriB3FmJZ9eL-RIFY3bs4f6RkN?usp=sharing](https://colab.research.google.com/drive/1_y_3darriB3FmJZ9eL-RIFY3bs4f6RkN?usp=sharing)

Dataset Drive para el código --> [https://drive.google.com/drive/folders/1NfG2M9UwezJLTHJ03iiMcX59kAPCaCft?usp=drive\\_link](https://drive.google.com/drive/folders/1NfG2M9UwezJLTHJ03iiMcX59kAPCaCft?usp=drive_link)

Apuntes --> probar un umap, t-sne. En vez del espectrograma, un logaritmo de la transformada de fourier...

[1] MIMII Dataset H. Purohit, R. Tanabe, K. Ichige, T. Endo, Y. Nikaido, K. Suefusa y Y. Kawaguchi, "MIMII Dataset: Sound Dataset for Malfunctioning Industrial Machine Investigation and Inspection," *arXiv preprint*, arXiv:1909.09347, 2019.

[2] DCASE 2019 H. Purohit, R. Tanabe, K. Ichige, T. Endo, Y. Nikaido, K. Suefusa y Y. Kawaguchi, "MIMII Dataset: Sound Dataset for Malfunctioning Industrial Machine Investigation and Inspection," en *Proceedings of the 4th Workshop on Detection and Classification of Acoustic Scenes and Events (DCASE)*, 2019.

[3] Mel-frequency cepstral coefficients S. Davis y P. Mermelstein, "Comparison of Parametric Representations for Monosyllabic Word Recognition in Continuously Spoken Sentences," *IEEE Transactions on Acoustics, Speech, and Signal Processing*, vol. 28, no. 4, pp. 357–366, 1980.

[4] Short-Time Fourier Transform D. Griffin y J. Lim, "Signal Estimation from Modified Short-Time Fourier Transform," *IEEE Transactions on Acoustics, Speech, and Signal Processing*, vol. 32, no. 2, pp. 236–243, 1984.

[5] Linear Discriminant Analysis R. A. Fisher, "The Use of Multiple Measurements in Taxonomic Problems," *Annals of Eugenics*, vol. 7, no. 2, pp. 179–188, 1936.

[6] Google Colaboratory Proyecto desarrollado en Google Colab

[7] MIMII Dataset Dataset descargado desde [Zenodo MIMII Dataset](#)

[8] Archivos de audio utilizados para las pruebas disponibles en Google Drive Dataset Folder